

# Relatório Técnico

**Projeto:** Sistema de Inteligência Artificial para Otimização de Estações de Carregamento de Veículos Elétricos

**Objetivo:** Desenvolver um sistema que prevê a demanda de energia em estações de carregamento de veículos elétricos e otimiza a alocação de recursos energéticos para reduzir custos e melhorar a eficiência.

## 1. Introdução

### 1.1 Contexto e Justificativa

O uso de veículos elétricos (VE) está crescendo muito rápido no mundo todo. Esse aumento é ótimo para o meio ambiente, pois os veículos elétricos não emitem gases poluentes. Mas, ao mesmo tempo, isso cria um grande desafio: é preciso garantir que existam estações de carregamento suficientes e que a energia seja distribuída de forma eficiente entre essas estações para que nenhum carro fique sem carga.

Esse projeto tem como objetivo criar um sistema que possa prever a quantidade de energia que cada estação vai precisar. Além disso, o sistema deve distribuir essa energia de uma forma que todas as estações tenham o suficiente, mas sem desperdício. Com isso, empresas que gerenciam redes de carregamento podem economizar nos custos de energia e melhorar o atendimento aos clientes.

## 2. Metodologia

### 2.1 Base de Dados Utilizada

A base de dados usada neste projeto foi a **Electric Vehicle Charging Stations 2024**, disponível no Kaggle ([link para a base de dados](#)). Essa base de dados contém informações sobre diversas estações de carregamento de veículos elétricos em várias regiões.

#### Descrição das Variáveis Principais

Abaixo estão as principais informações que usamos da base de dados:

- New Georeferenced Column:** Essa coluna mostra a localização de cada estação com as coordenadas de latitude e longitude.
- EV Level1 EVSE Num:** Número de carregadores de nível 1 (carregadores mais lentos).
- EV Level2 EVSE Num:** Número de carregadores de nível 2 (carregadores de velocidade média).


4. **EV DC Fast Count:** Número de carregadores rápidos (DC), que são ideais para quem precisa de uma carga rápida.
5. **Total Chargers:** Número total de carregadores em cada estação, que foi criado somando os carregadores dos diferentes níveis.

Essa base de dados foi escolhida porque fornece informações suficientes para simular a demanda de energia e otimizar a distribuição entre as estações.

### Visualizações e Análise Exploratória


Para compreender melhor o perfil das estações de carregamento e simular a demanda de energia, criamos alguns gráficos baseados nas principais variáveis da base de dados

#### Distribuição do Número Total de Carregadores:




- Este gráfico mostra a **distribuição do número total de carregadores** disponíveis em cada estação de carregamento. Observamos que a maioria das estações possui entre 1 e 3 carregadores, enquanto poucas estações têm mais de 10 carregadores. Essa distribuição indica que a maioria das estações é de pequena capacidade, o que pode impactar a quantidade de veículos que elas conseguem atender simultaneamente. Estações com maior número de carregadores são menos frequentes, possivelmente localizadas em áreas de maior demanda ou utilizadas para atender um volume maior de usuários.
- **Interpretação:** A concentração de estações com poucos carregadores sugere uma rede de carregamento voltada para áreas de baixa ou média demanda. Esse padrão é importante, pois ajuda a planejar a distribuição de energia de acordo com a capacidade e a localização das estações.

### Distribuição Geográfica das Estações de Carregamento:



- Este gráfico mostra a **distribuição geográfica** das estações de carregamento com base em suas coordenadas de latitude e longitude. A quantidade de carregadores em cada estação é representada pela cor de cada ponto, com cores mais claras indicando um maior número de carregadores. Vemos uma maior concentração de estações em determinadas regiões, o que sugere que essas áreas têm maior demanda por carregamento de veículos elétricos.
- **Interpretação:** As áreas com maior densidade de estações são provavelmente locais com grande circulação de veículos elétricos, como centros urbanos ou rodovias principais. Essa visualização ajuda a identificar onde a infraestrutura de carregamento é mais densa e quais áreas poderiam precisar de mais estações ou de estações com maior capacidade.

### Distribuição da Demanda Simulada:



- O gráfico acima apresenta a **distribuição da demanda simulada** para cada estação de carregamento. A demanda foi simulada multiplicando o número de carregadores por uma faixa de valores aleatórios para representar uma estimativa de uso. A

maioria das estações tem uma demanda simulada entre 1 e 5 unidades, com algumas estações apresentando demanda mais elevada. Isso reflete a capacidade e o potencial de uso em cada estação.

- **Interpretação:** Esse gráfico de demanda simulada indica que a maioria das estações não tem uma carga de energia muito elevada, o que pode significar que muitas estações operam em áreas de demanda mais baixa. Para as estações com demanda mais alta, uma estratégia de otimização mais rigorosa seria necessária para garantir que a energia seja alocada adequadamente, atendendo a essa maior necessidade sem causar sobrecarga.

## 2.2 Pré-processamento e Criação de Variáveis (Engenharia de Features)

Para preparar o conjunto de dados, fizemos alguns ajustes:

1. **Extração de Coordenadas Geográficas:** Latitude e longitude foram extraídas da coluna `New Georeferenced Column` para analisar a localização das estações.
2. **Conversão de Dados:** Transformamos os números de carregadores de cada tipo para valores numéricos. Onde havia valores ausentes, substituímos por zero.
3. **Simulação da Demanda:** Como não havia dados reais de consumo, criamos uma variável chamada `simulated_demand` para representar uma demanda simulada de energia. Multiplicamos o total de carregadores em cada estação por um número aleatório entre 1 e 2 para gerar essa estimativa de demanda.

## 2.3 Modelo de Previsão de Demanda


Para prever a quantidade de energia necessária em cada estação, usamos uma **rede neural**. Redes neurais são modelos que conseguem aprender padrões complexos nos dados, tornando-se úteis para previsões precisas.

- **Estrutura do Modelo:** A rede neural foi configurada com três camadas densas, usando a função de ativação "ReLU".
- **Treinamento do Modelo:** O modelo foi treinado em 50 ciclos, utilizando 20% dos dados para validação, o que ajuda a medir a precisão.
- **Avaliação:** O desempenho do modelo foi medido usando o Erro Quadrático Médio (MSE), que calcula o quanto o modelo erra nas previsões.

### Comparação com Modelos Alternativos

Para ver se a rede neural realmente era a melhor opção, também testamos um modelo de **Regressão Linear** e comparamos os resultados.

- **Gráfico de Comparação de Modelos:**



- Este gráfico compara o **Erro Quadrático Médio (MSE)** entre dois modelos de previsão: a **Rede Neural** e a **Regressão Linear**. O MSE é uma medida de erro que indica o quanto as previsões feitas pelo modelo se desviam dos valores reais, sendo que valores menores de MSE indicam previsões mais precisas.
- **Interpretação:** Observa-se que o MSE da **Regressão Linear** é menor do que o da **Rede Neural**. Isso sugere que, neste caso, a regressão linear foi capaz de capturar melhor o padrão dos dados e fazer previsões mais precisas do que a rede neural. Esse resultado pode ocorrer quando a relação entre as variáveis é relativamente simples, o que permite que a regressão linear, um modelo mais direto, se ajuste melhor aos dados. No entanto, em casos mais complexos, a rede neural geralmente possui vantagem, pois pode modelar padrões mais complexos.
- Essa análise nos ajuda a entender as limitações e pontos fortes de cada modelo, guiando a escolha para futuros aprimoramentos do sistema. Para dados com características mais complexas, uma rede neural ajustada pode oferecer melhores resultados, enquanto para padrões mais lineares, a regressão linear pode ser mais eficiente.

## 2.4 Otimização de Recursos com Programação Linear

Após prever a demanda, fizemos uma otimização para distribuir a energia entre as estações de forma eficiente. Usamos **programação linear**, que é uma técnica matemática para encontrar a melhor solução com restrições.

### Parâmetros de Otimização

- **Objetivo:** Minimizar o custo total de energia, garantindo que cada estação receba uma quantidade mínima.
- **Restrições:**
  - Cada estação deve receber pelo menos 50% da sua demanda simulada.
  - A energia total distribuída não pode passar de 1.000 unidades para evitar sobrecarga.

Essa otimização ajuda a garantir que a energia seja usada de forma eficiente e que os custos sejam controlados.

---

### 3. Resultados


#### 3.1 Avaliação do Modelo de Previsão

O modelo de previsão (rede neural) apresentou um **Erro Quadrático Médio (MSE)** de aproximadamente **1.25**, indicando que ele fez previsões precisas para a demanda de energia em cada estação.

#### 3.2 Resultados da Otimização

Depois de prever a demanda, distribuímos a energia entre as estações usando a otimização. Coloque aqui os gráficos que ajudam a entender esses resultados:


- **Distribuição da Energia Alocada após Otimização:**



- Este gráfico mostra a **distribuição da quantidade de energia alocada** para cada estação após o processo de otimização. Observa-se que a maior parte das estações recebeu entre 1 e 2 unidades de energia, com poucas estações recebendo alocações mais elevadas (até 10 unidades). Essa distribuição indica que o sistema de otimização alocou a energia de forma eficiente, concentrando os recursos nas estações com maior demanda e mantendo o consumo geral dentro dos limites estabelecidos.
- **Interpretação:** A predominância de valores baixos de energia alocada reflete uma alocação ajustada, onde a maioria das estações recebeu uma quantidade de energia suficiente para atender a uma demanda mais moderada. As poucas alocações altas sugerem que algumas estações

apresentaram demandas excepcionais, e o sistema foi capaz de identificar e atender essas necessidades, respeitando as restrições de capacidade.

- **Comparação entre Demanda Prevista e Energia Alocada:**



- Este gráfico compara a **demanda prevista** com a **energia realmente alocada** para cada estação. A linha vermelha tracejada representa a alocação ideal, onde a energia alocada seria exatamente igual à demanda prevista. A maioria dos pontos se concentra abaixo da linha, o que indica que, em muitos casos, a energia alocada foi ligeiramente inferior à demanda, possivelmente devido às restrições de capacidade total.
- **Interpretação:** Esse gráfico revela que o sistema de otimização priorizou uma distribuição equilibrada, atendendo à demanda prevista dentro das limitações de recursos. A proximidade dos pontos com a linha ideal indica que a alocação foi precisa para a maioria das estações. As pequenas variações abaixo da linha mostram que o sistema foi capaz de gerenciar as restrições de capacidade, fazendo ajustes mínimos na alocação sem comprometer o atendimento das estações de alta demanda.

### **Análise de Sensibilidade**

Para verificar a flexibilidade do sistema, ajustamos alguns parâmetros, como o custo unitário e a capacidade máxima. Descobrimos que, ao aumentar o custo, o sistema ajustou automaticamente para manter a eficiência. E ao aumentar a capacidade máxima, o sistema conseguiu atender ainda mais da demanda total.

## 4. Conclusão e Melhorias Futuras

### Conclusão

Este projeto desenvolveu um sistema inteligente que utiliza técnicas de Machine Learning e otimização para prever a demanda de energia e alocar recursos de forma eficiente em estações de carregamento de veículos elétricos. O modelo de rede neural implementado foi capaz de captar padrões nos dados, resultando em previsões de demanda razoavelmente precisas, enquanto o uso de programação linear permitiu otimizar a distribuição de energia com base em critérios de custo e capacidade máxima.

Os resultados obtidos mostram que o sistema pode atender a diferentes demandas de maneira eficiente, com alocação ajustada às estações de maior demanda e controle de custo de energia. Ao comparar a rede neural com um modelo de regressão linear, observamos que a regressão linear apresentou menor Erro Quadrático Médio (MSE) nos dados, sugerindo que, para esta base de dados, um modelo linear mais simples foi mais eficaz.

### Limitações:

1. **Demanda Simulada:** Como o sistema foi baseado em uma demanda simulada, a precisão do modelo pode ser limitada, pois ele não reflete dados reais de uso. Essa simulação foi útil para avaliar o sistema, mas o uso de dados reais poderia aumentar a acurácia das previsões e a eficiência da alocação de recursos.
2. **Simplicidade da Programação Linear:** A programação linear usada para otimização é uma técnica eficaz, mas pode ser limitada para cenários mais complexos com múltiplas restrições variáveis.

### Melhorias Futuras:

1. **Coleta de Dados Reais:** Uma das melhorias mais impactantes para este sistema seria a coleta de dados reais de consumo de energia nas estações de carregamento. Dados reais poderiam substituir a demanda simulada, permitindo que o modelo faça previsões mais precisas, adequadas às necessidades reais de cada estação. Isso melhoraria a eficácia do sistema e aumentaria a confiança das previsões, garantindo que a distribuição de energia seja ainda mais eficiente e precise de menos ajustes.
2. **Ajustes para Horários de Pico:** O sistema poderia se beneficiar de ajustes específicos para lidar com variações nos horários de pico. Ao incorporar dados temporais, o modelo poderia prever períodos de alta e baixa demanda com mais precisão, ajustando a alocação de recursos conforme necessário. Esse aprimoramento garantiria que as estações estivessem preparadas para atender ao aumento na demanda, sem desperdício de energia fora dos horários de pico.
3. **Técnicas Avançadas de Otimização:** Para cenários onde a alocação de energia exige mais complexidade, como diferentes tipos de carregadores ou restrições adicionais, a introdução de técnicas de otimização avançadas, como algoritmos evolutivos, poderia ser vantajosa. Esses algoritmos oferecem flexibilidade para otimizações não lineares, o que permitiria ao sistema lidar com uma gama mais



ampla de restrições e variáveis. Em aplicações reais, isso se traduz em uma alocação de energia ainda mais eficaz e ajustada às demandas.

4. **Integração com Dados de Previsão Climática:** Incorporar dados climáticos ao modelo poderia representar uma vantagem estratégica, pois o clima influencia a frequência de uso dos veículos elétricos. Em dias chuvosos ou frios, por exemplo, a demanda por carregamento pode ser reduzida. A integração desses dados no sistema permitiria previsões mais precisas e melhor ajuste da alocação de recursos.

## Implementação Prática

Este sistema de previsão e otimização para estações de carregamento de veículos elétricos pode ser integrado em plataformas reais de gestão de energia para melhorar a eficiência e reduzir os custos de operação. Abaixo estão algumas sugestões de como essa implementação pode ocorrer na prática:

1. **Integração com um Sistema de Gestão de Estações (SGE):**
  - A plataforma de gestão de estações de carregamento poderia ser desenvolvida como uma aplicação web ou uma aplicação móvel que se integra diretamente com o sistema de previsão e otimização de demanda.
  - Essa plataforma centralizada permitiria monitorar em tempo real a demanda de cada estação, ajustar as alocações de energia, e responder rapidamente a mudanças de demanda.
2. **Tecnologias Recomendadas para Desenvolvimento da Plataforma:**
  - **Backend:** A aplicação pode ser implementada em linguagens e frameworks robustos como Python (Django, Flask) ou Node.js (Express) para lidar com as previsões e otimizações.
  - **Frontend:** Tecnologias como React, Angular ou Vue.js podem ser utilizadas para desenvolver uma interface de usuário intuitiva, permitindo aos operadores das estações monitorar as demandas e alocações de energia de forma visual e acessível.
  - **Banco de Dados:** Bancos de dados relacionais (como PostgreSQL) ou NoSQL (como MongoDB) podem ser utilizados para armazenar informações sobre a demanda histórica, previsões de consumo, e alocações de energia de cada estação.
3. **Interação com Dispositivos IoT em Estações de Carregamento:**
  - Estações de carregamento modernas são frequentemente equipadas com sensores e dispositivos IoT (Internet das Coisas) que monitoram o consumo de energia em tempo real.
  - Integrar o sistema com esses dispositivos IoT permitiria coletar dados em tempo real sobre o uso de cada carregador e atualizar continuamente a previsão de demanda.
  - Protocolos de comunicação como **MQTT** (Message Queuing Telemetry Transport) ou **HTTP REST API** são comumente usados para a troca de dados entre dispositivos IoT e servidores de backend.
4. **Painel de Controle e Visualização de Dados:**
  - Um painel de controle pode ser implementado na plataforma para mostrar visualização em tempo real da demanda e alocação de energia. Essas visualizações podem incluir:

- **Mapas de Calor** para identificar regiões com maior demanda.
  - **Gráficos de Linha** para monitorar o consumo de energia ao longo do tempo.
  - **Alertas e Notificações** que informam os operadores quando uma estação está em risco de sobrecarga ou se a alocação de energia precisa ser ajustada.
5. **Automação e Resposta Rápida a Mudanças de Demanda:**
- A plataforma pode incluir uma função de automação que ajusta a alocação de energia de forma dinâmica com base em dados em tempo real. Quando a demanda em uma área aumenta repentinamente, o sistema ajusta automaticamente a distribuição de energia entre as estações próximas, evitando sobrecargas e otimizando o uso dos recursos.
  - **Machine Learning em Tempo Real:** Para melhorar ainda mais a previsão de demanda, o sistema pode ser configurado para treinar o modelo de machine learning de forma incremental à medida que novos dados são coletados. Isso permite que o modelo se adapte a padrões de consumo que mudam ao longo do tempo.
6. **Uso de APIs de Previsão de Energia e Tempo:**
- A previsão de demanda para veículos elétricos pode ser afetada por condições climáticas e outros fatores externos. A integração com APIs externas, como APIs meteorológicas (exemplo: OpenWeatherMap) e APIs de previsão de demanda energética, pode permitir ao sistema considerar esses fatores e ajustar as previsões e alocações de energia de acordo.

## Benefícios para Operadores de Estações de Carregamento

- **Redução de Custos:** Com uma previsão e alocação mais precisa da energia, o sistema ajuda a minimizar desperdícios, o que resulta em redução de custos operacionais para empresas.
- **Melhoria na Satisfação do Cliente:** Uma gestão eficiente da demanda evita situações de indisponibilidade de carregamento, melhorando a experiência dos usuários de veículos elétricos.
- **Sustentabilidade:** A alocação otimizada de energia reduz o consumo desnecessário e torna o sistema mais sustentável, contribuindo para práticas de energia renovável e eficiência energética.

## Requisitos para Implementação

- **Dependências:** É necessário ter as bibliotecas **TensorFlow**, **SciPy**, **Pandas**, e **NumPy** instaladas para realizar a previsão e otimização de demanda.
- **Execução em Nuvem:** Para ambientes em larga escala, recomenda-se hospedar o sistema em servidores de nuvem (ex.: AWS, Google Cloud, Microsoft Azure) para facilitar o processamento de dados em tempo real e a escalabilidade.
- **Segurança e Conformidade:** Como o sistema lida com dados sensíveis de infraestrutura, é fundamental implementar práticas de segurança (como autenticação, criptografia e monitoramento de rede) e garantir a conformidade com regulamentações locais.

Com esses detalhes, o sistema proposto pode ser usado por empresas de gerenciamento de estações de carregamento de veículos elétricos para economizar energia e otimizar o uso dos recursos de forma prática e eficiente. Com as melhorias sugeridas, ele pode se tornar uma ferramenta essencial na gestão de redes de carregamento e ajudar a enfrentar os desafios do crescimento no uso de veículos elétricos.

## 5. Anexos

- **Código Completo:** O código deste projeto está disponível no repositório do projeto [\(inserir link aqui\)](#).
- **Instruções para Execução:**
  - **Requisitos:** É necessário ter as bibliotecas Tensor Flow, SciPy, Pandas e NumPy instaladas.
  - **Execução:** O código pode ser executado em um ambiente Jupyter Notebook ou Google Colab, o que facilita a visualização dos gráficos e dos resultados.

## 6. Referências

- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.
- Li, X., Sun, T., Feng, Z., & Yang, G. (2019). Demand Response Strategy in Electric Vehicle Charging Station Considering Time-of-Use Electricity Price and Battery Degradation Cost. *IEEE Access*, 7, 108137-108145.
- Sierzechula, W., Bakker, S., Maat, K., & van Wee, B. (2014). The influence of financial incentives and other socio-economic factors on electric vehicle adoption. *Energy Policy*, 68, 183-194.
- Winston, W. L. (2004). *Operations Research: Applications and Algorithms*. Duxbury Press.